

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Уральский федеральный университет
имени первого Президента России Б.Н. Ельцина»

Институт радиоэлектроники и информационных технологий – РТФ
Школа профессионального и академического образования

ДОПУСТИТЬ К ЗАЩИТЕ ПЕРЕД ГЭК

	РОП
(подпись)	Борисов В.И.
« »	(Ф.И.О.)
	2023 г.

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

ИСПОЛЬЗОВАНИЕ МАШИННОГО ОБУЧЕНИЯ ДЛЯ
АВТОМАТИЧЕСКОЙ ИНТЕРПРЕТАЦИИ ДАННЫХ
ИЗ СИСТЕМ ВЕБ-АНАЛИТИКИ

Научный руководитель: Долганов Антон Юрьевич
к.т.н., доцент

Нормоконтролер: Огуренко Е.В.

Студент группы РИМ–210962 Цинцов Никита Валерьевич





Екатеринбург
2023

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования «Уральский федеральный университет имени первого
Президента России
Б.Н. Ельцина»

Институт радиоэлектроники и информационных технологий – РтФ
Школа профессионального и академического образования
Направление подготовки Информатика и вычислительная техника
Образовательная программа Инженерия машинного обучения

УТВЕРЖДАЮ

РОП _____
« ____ » _____ 2023 г.

ЗАДАНИЕ

на выполнение выпускной квалификационной работы

студента Цинцова Никиты Валерьевича группы РИМ-210962
(фамилия, имя, отчество)

1. Тема выпускной квалификационной работы «Использование машинного обучения для автоматической интерпретации данных из систем веб аналитики»

Утверждена распоряжением по институту от « ____ » _____ 2023 г. № _____

2.Руководитель Долганов Антон Юрьевич, доцент, к.т.н.,
доцент _____

(Ф.И.О., должность, ученое звание, ученая степень)

3. Исходные данные к работе

Набор данных представленный ООО «Систем проджектс» по работе одного из их продуктов.

4. Перечень демонстрационных материалов

Рисунки и таблицы для описания основных подходов к решению задачи

5. Календарный план

№ п/п	Наименование этапов выполнения работы	Срок выполнения этапов работы	Отметка о выполнен ии
1.	<i>1. Обзор подходов к решению задачи</i>	до 15.04.2023 г.	

2.	2. Разработка структуры решения	до 03.05 2023 г.	
3.	3. Реализация алгоритма интерпретации	до 19.05.2023 г.	
4.	ВКР в целом	до 01.06 2023 г.	

Руководитель _____
Долганов А.Ю.

(подпись)

Ф.И.О.

Задание принял к исполнению _____

дата

(подпись)

6. Выпускная квалификационная работа закончена «05» июня 2023г. считаю возможным допустить Цинцова Никиту Валерьевича к защите выпускной квалификационной работы закончена в Государственной экзаменационной комиссии.

Руководитель _____
А.Ю.

(подпись)

Долганов

Ф.И.О.

7. Допустить Цинцова Никиту Валерьевича к защите магистерской диссертации в Государственной экзаменационной комиссии.

РОП _____

(подпись)

Ф.И.О.

Аннотация

В данной работе был разработан и реализован комплексный подход к анализу и интерпретации пользовательских данных, собранных в рамках системы веб-аналитики. Применяя методы машинного обучения и аналитики данных, были исследованы и выявлены ключевые события пользователей, влияющие на определенные бизнес-метрики.

Начальные этапы проекта включали сбор и предварительную обработку данных, с последующей кластеризацией для выявления скрытых взаимосвязей и структур. Использовались или тестировались различные библиотеки для объяснимости работы моделей машинного обучения, такие как Eli5 и SHAP. Для решения задачи тестировались кластеризации, включая K-средних, DBSCAN, спектральную кластеризацию и OPTICS. В качестве алгоритмов применялась логистическая регрессия, случайный лес и CatBoost. Применялась нейронная сеть.

Для определения значимости признаков использовались методы Permutation Importance, с применением моделей логистической регрессии, случайного леса и нейронной сети.

Основным результатом стала разработка скрипта, осуществляющего автоматический сбор, обработку данных и определение наиболее значимых событий. Полученный инструментарий значительно облегчает задачу аналитиков, помогая определять ключевые аспекты поведения пользователей и строить более эффективные стратегии взаимодействия.

Применение полученных результатов имеет высокий потенциал для улучшения бизнес-решений и оптимизации работы с пользовательской аудиторией.

Содержание

Аннотация	4
Введение	7
1. Автоматизация анализа данных: сложности ручной интерпретации данных из систем веб-аналитики.....	10
1.1 Подходы к сбору данных	10
1.2 Обзор основных систем сбора данных о поведении пользователей.....	12
1.2.1 Яндекс.Метрика	12
1.2.2 Google Analytics	13
1.2.3 Adobe Analytics	13
1.2.4. Amplitude	14
1.2.5. Собственные системы аналитики компаний.....	15
1.3 Сырые данные систем веб аналитики и проблемы в работе с ними.....	16
1.4 Обзор решений для автоматизации интерпретации данных	18
1.4.1 Microsoft Power BI.....	18
1.4.2 Tableau	19
1.4.3 Google Data Studio.....	20
1.4.4 QlikSense	21
1.4.5 Yandex DataLens.....	21
1.4.6 Российские BI-системы.....	22
1.5 Вывод	23
Глава 2. Датасет и инструменты для анализа.....	26
2.1 Базовые данные систем веб аналитики.....	26
2.2 Датасет используемый в работе	28
2.3 Инструменты для решения задачи	30
2.4 Алгоритмы машинного обучения использованные в работе	35
2.5 Этические аспекты.....	38

2.6 Вывод	39
3. Разработка программной реализации инструмента для автоматической интерпретации данных из систем веб аналитики.....	42
3.1 Описание задачи	42
3.2 Сбор и подготовка данных.....	43
3.3. Разработка реализации	45
3.3.1 Кластеризация	45
3.3.2 Использование кластера в качестве целевого признака при классификации с помощью CatBoost.....	49
3.3.3 Eli5.....	52
3.3.4 Извлечение ключевых факторов влияния из нейронной сети.....	54
3.3.5. Ранговая система финального вывода	57
3.4 Итоговая реализация.....	59
Заключение.....	61
Список литературы и ресурсов	63

Введение

В современном мире технологии охватывают все сферы жизни общества, а большинство нашей ежедневной активности проходит на сайтах и приложениях для смартфона. В таком мире аналитика пользовательских данных играет ключевую роль в управлении веб-продуктами и в их развитии. Она позволяет компаниям развивающим сайты или приложения мониторить и анализировать данные о поведении пользователей и их взаимодействии с интерфейсом, что в конечном итоге обеспечивает наиболее точное представление о том, как оптимизировать, улучшать и в какую сторону развивать продукт для лучшего удовлетворения потребностей клиентов и улучшения коммерческих свойств.

Особую роль продуктовых командах разработки играет аналитик данных. Он выполняет широкий спектр задач на всем пути ETL-процесса (Extract, Transform, Load): поиск, систематизация данных, обработка, использование и имплементация ML-алгоритмов, анализ больших объемов табличных данных, поиск гипотез для увеличения ключевых метрик продукта [1].

Одна из основных проблем, стоящих перед аналитиком данных, заключается в необходимости проведения ручного поиска и интерпретации гипотез для улучшения продукта. Аналитику часто приходится просматривать большие объемы данных и устанавливать связи между различными переменными, чтобы выявить возможные факторы, влияющие на ключевые показатели продукта. Эта задача может быть трудоемкой, что в свою очередь может привести к увеличению времени на оптимизацию продукта. А в условиях постоянного роста объема обрабатываемых данных, может негативно сказываться на качестве исследований и поиска гипотез. Кроме того, этот процесс подвержен ошибкам, поскольку аналитики могут пропустить важные связи или неверно интерпретировать данные, как вследствие ограничений собственного опыта так и в результате нехватки времени в условиях жестко ограниченных временных рамок команды. Как

правило аналитик выполняет задачи, результаты которых нужны были команде «еще вчера». Все это может привести к тому, что аналитик будет замечать самые очевидные гипотезы, так называемые low-hanging fruit, пропуская более сложные.

Поэтому все чаще в работе аналитика возникает потребность в автоматическом предварительном поиске и интерпретации табличных данных из систем веб-аналитики, в том числе с использованием алгоритмов машинного обучения. Введение автоматизированных систем для интерпретации табличных данных из веб-аналитики может существенно облегчить процесс анализа данных и выявления важных зависимостей, что позволит аналитику сосредоточиться на более тонких аспектах своей работы и принимать более эффективные решения по развитию продукта.

Под автоматической интерпретацией табличных данных подразумевается процесс, в котором с помощью алгоритмов машинного обучения анализируются и выявляются важные зависимости между переменными в представленных данных. Это позволяет выявлять закономерности, которые могут быть использованы для формирования гипотез и предложений по оптимизации продукта. Такой подход может сократить время, необходимое для анализа данных, а также уменьшить возможность ошибок, связанных с человеческим фактором, а также может способствовать повышению качества аналитических выводов.

Для успешного внедрения автоматической интерпретации табличных данных, необходимо также разработать набор лучших практик для обработки и подготовки данных, так как качество данных существенно влияет на качество результатов. В качестве перспективных в этом направлении видятся алгоритмы кластеризации, модели классификации, деревья решений. А в качестве вспомогательных к ним наборы методов для объяснений работы этих алгоритмов.

Итак, автоматическая интерпретация табличных данных из систем веб-аналитики с использованием машинного обучения является перспективным

направлением для повышения эффективности и качества работы аналитика данных. Внедрение таких систем может существенно облегчить процесс анализа данных и выявления важных зависимостей, позволяя аналитикам сосредоточиться на формировании стратегий и решений для улучшения продуктов и достижения более высоких результатов в своей работе.

1. Автоматизация анализа данных: сложности ручной интерпретации данных из систем веб-аналитики

1.1 Подходы к сбору данных

Все основные системы веб аналитики собирают данные основываясь на двух основных подходах к сбору и хранению данных о посещениях и взаимодействиях: основанный на данных о визитах (далее visit based) и основанный на данных о пользователях (далее user based) [2].

Visit-based аналитика фокусируется на основании отслеживания действий в рамках одного посещения сайта или сессии. Данный подход предполагает, что каждая сессия представляет собой отдельное взаимодействие пользователя с сайтом. Это означает, что если пользователь посещает сайт дважды в течение одного дня, он будет считаться как два разных посещения. На основе visit based подхода, например, работают Yandex Метрика, Google Analytics и Adobe Analytics.

User based аналитика сосредоточена на поведении конкретного пользователя, независимо от числа посещений или сессий. В этом подходе акцент делается на анализе истории действий каждого пользователя, чтобы получить глубокое понимание их предпочтений, поведения и конверсий. Это позволяет определить общие закономерности и наиболее ценные группы пользователей. User based подход используют, например, Amplitude, Mixpanel и Heap.

Выбор между visit based и user based подходами зависит от целей и приоритетов в развитии продукта, а также зависит от его характера и модели монетизации. Visit based подход может быть полезным для определения ключевых моментов взаимодействия в рамках одной сессии, таких как посещение определенных страниц, отказы или продолжительность сессии. Такой подход хорошо работает с веб-сайтами, на которых аудитория все время обновляется. А также успешность в прохождении воронки пользователем в рамках одного изолированного взаимодействия. User based подход же больше подходит для анализа поведения и профилей пользователей в долгосрочной

перспективе, таких как отслеживание повторных покупок, удержание пользователей и их жизненный цикл. Такой подход хорошо себя показывает в продуктах с подписной моделью монетизации.

В дальнейшей работе будет использоваться user based подход, потому что он позволяет лучше понимать долгосрочное взаимодействие пользователей с продуктом. Это даст возможность определить сильные и слабые стороны продукта. Анализировать историю взаимодействий, что помогает определить факторы, влияющие на удовлетворенность и успешность пользователей. Сегментировать пользователей на основе их поведения и интересов, что облегчает разработку персонализированных предложений и стратегий маркетинга. Оценить долгосрочную ценность пользователя

Кроме того, одной из проблем использования данных по сессиям для аналитических выводов, является использование статистических методов, например, таких как z-критерий. Проблема заключается в том, что сессии часто не являются независимыми и идентично распределенными наблюдениями, что является базовым предположением для многих статистических тестов. Сессии могут не быть независимыми из-за зависимости внутри пользователя. Один пользователь может совершить несколько сессий, и его поведение в одной сессии может быть связано с его поведением в другой сессии. Например, пользователь может искать информацию о продукте в одну сессию и вернуться на следующий день, чтобы сделать покупку. Эти сессии взаимосвязаны, но z-критерий предполагает независимость наблюдений.

User based подход, учитывает зависимости и разнообразие поведения пользователей

Таким образом, использование user based подхода при анализе данных из систем веб-аналитики обеспечивает более глубокое понимание поведения пользователей и позволяет разрабатывать продукты, максимально соответствующие их потребностям и предпочтениям.

1.2 Обзор основных систем сбора данных о поведении пользователей

Системы веб-аналитики становятся незаменимым инструментом для любого бизнеса присутствующего в интернете, стремящегося к повышению эффективности своей работы. Эти системы предоставляют богатый набор данных о поведении пользователей, которые могут быть использованы для глубокого анализа и выработки стратегий в области продаж, маркетинга, разработки продуктов и улучшения пользовательского опыта. Следующий обзор основных систем веб-аналитики позволит более подробно понять их функционал, возможности и преимущества для решения конкретных задач в области анализа данных.

1.2.1 Яндекс.Метрика

Система веб-аналитики, разработанная компанией Яндекс для сбора и анализа данных о посетителях веб-сайтов и мобильных приложений. Она позволяет отслеживать ключевые метрики в реальном времени, такие как количество пользователей, демографические данные, поведение пользователей на сайте и конверсии. Яндекс Метрика также предоставляет визуализацию данных в форме графиков и отчетов, что упрощает интерпретацию информации. Однако, несмотря на широкий набор инструментов, система не предлагает автоматическую интерпретацию большого объема данных и возможностей машинного обучения для обработки и анализа информации [3].

Плюсы:

- Бесплатный инструмент с широким функционалом
- Поддержка на русском языке и интеграция с другими продуктами Яндекс
- Вебвизор для отслеживания поведения пользователей в реальном времени

Минусы:

- Меньше возможностей и гибкости, чем у систем с обширной экосистемой, такими как Google Analytics и Adobe Analytics

- Преимущественно ориентирована на российский рынок

1.2.2 Google Analytics

Популярная система веб-аналитики, разработанная компанией Google для сбора, отслеживания и анализа данных о трафике и поведении пользователей на веб-сайтах и мобильных приложениях. Она предоставляет множество метрик и инструментов визуализации, таких как графики, таблицы и сегменты, что помогает аналитикам получить детальную картину пользовательского опыта. Кроме того, Google Analytics интегрируется с другими сервисами Google, такими как Google Ads и Google Data Studio, что позволяет объединить и анализировать данные из разных источников. Однако, подобно Яндекс Метрике, Google Analytics не предоставляет возможностей автоматической интерпретации данных и машинного обучения для обработки и анализа информации [4].

Плюсы:

- Бесплатная версия с богатыми возможностями
- Мощная интеграция с другими продуктами Google
- Огромное сообщество и многообразие ресурсов для обучения

Минусы:

- Сложность настройки и использования для новичков
- Ограничения в отношении защиты данных и конфиденциальности

1.2.3 Adobe Analytics

Система веб-аналитики, предназначенная для сбора, обработки и анализа информации о трафике и поведении пользователей на сайтах и мобильных приложениях. Adobe Analytics является частью Adobe Experience Cloud и интегрируется с другими продуктами компании, такими как Adobe Target и Adobe Audience Manager. Эта система предоставляет богатый набор инструментов для анализа данных, включая сегментацию, визуализацию и предиктивный анализ. Однако, несмотря на свою мощь и гибкость, Adobe Analytics также не обладает встроенными возможностями автоматической

интерпретации данных и использования машинного обучения для формирования гипотез [5].

Плюсы:

- Глубокий анализ данных с многочисленными метриками и сегментами
- Часть экосистемы Adobe Experience Cloud
- Интеграция с другими продуктами Adobe

Минусы:

- Высокая стоимость и сложность настройки для малых и средних предприятий
- Требуется опыта и обучения для использования полного потенциала продукта

1.2.4. Amplitude

Система веб-аналитики, ориентированная на анализ поведения пользователей и оптимизацию продуктовых метрик. Amplitude предоставляет функциональность для отслеживания событий и метрик, связанных с пользовательским взаимодействием, а также инструменты для глубокого анализа поведения отдельных пользователей и групп. Визуализация данных в Amplitude представляет собой интуитивно понятные графики, что облегчает интерпретацию информации. Однако, несмотря на свою силу в анализе поведения пользователей, Amplitude не предлагает автоматическую интерпретацию данных и возможности машинного обучения для выявления гипотез [6].

Плюсы:

- Глубокий анализ пользовательского поведения
- Интеграция с другими платформами: Amplitude легко интегрируется с другими инструментами и платформами, такими как Google Analytics, Segment, Intercom и другими.
- Масштабируемость и производительность: Amplitude способна обрабатывать огромные объемы данных

- Событийная аналитика: Amplitude позволяет собирать данные на основе событий, что обеспечивает гибкость и детализацию анализа.

Минусы:

- Сложность настройки
- Для малого и среднего бизнеса стоимость использования Amplitude может быть довольно высокой, особенно с учетом дополнительных функций и возможностей.
- Ограниченный функционал в бесплатной версии
- В некоторых случаях, Amplitude может требовать дополнительного времени на обработку больших объемов данных, что может замедлить процесс получения важной информации и анализа результатов.

1.2.5. Собственные системы аналитики компаний

Некоторые компании разрабатывают и используют собственные системы веб-аналитики, чтобы точнее удовлетворить свои уникальные потребности и контролировать процесс сбора и анализа данных. Собственные системы обычно создаются с учетом уникальных потребностей компании и интегрируются с ее внутренними инструментами и процессами. Использование собственных систем аналитики может дать компании больший контроль над своими данными и возможность создавать специализированные инструменты и отчеты.

Плюсы:

- Полная кастомизация под уникальные потребности и требования компании
- Более высокий уровень контроля над данными и их конфиденциальностью
- Возможность интеграции с существующими системами и процессами

Минусы:

- Высокая стоимость разработки и поддержки собственной системы аналитики

- Отсутствие готовых решений и сообщества, которые могут помочь с обучением и разрешением проблем

Существует множество систем веб-аналитики на рынке, каждая из которых имеет свои преимущества и недостатки. Собственные системы аналитики кампаний могут быть наилучшим выбором для организаций, которые требуют высокой степени кастомизации и контроля над данными.

1.3 Сырые данные систем веб аналитики и проблемы в работе с ними.

Сырые данные (raw data) в системах веб-аналитики представляют собой первичную информацию, собранную об активности пользователей на сайте или в мобильном приложении. Это необработанные и неструктурированные записи о поведении пользователей, посещениях, конверсиях и других метриках. Эти данные включают в себя разнообразную информацию, такую как время посещения, длительность сессии, просмотренные страницы, события, местоположение, тип устройства, источник трафика и множество других параметров. Сырые данные служат основой для всех аналитических отчетов, агрегированных и сегментированных данных, которые в дальнейшем используются для анализа и оптимизации веб-ресурсов и мобильных приложений.

В системах веб-аналитики, таких как Яндекс.Метрика и Google Analytics, доступ к сырым данным обычно ограничен, поскольку эти системы фокусируются на предоставлении агрегированных и сегментированных отчетов [7]. Однако, для Яндекс.Метрика доступ к сырым данным может быть получен через API Логов визитов, а для Google Analytics – через API Core Reporting. Amplitude и Adobe Analytics также предоставляют доступ к сырым данным через соответствующие API, которые позволяют экспортировать информацию о событиях и пользователях. В случае собственных систем аналитики, как правило, проблем с доступом к сырым данным не возникает.

Работа с сырыми данными (raw data) из систем аналитики может представлять значительные вызовы и проблемы. Современные системы веб-

аналитики генерируют огромные объемы данных, обычно представляют из себя довольно внушительный объем информации, который может измеряться миллиардами строк. Такие данные сложно обрабатывать, хранить и анализировать. Обработка таких объемов данных требует мощных вычислительных ресурсов. Кроме того, сырые данные могут содержать дубликаты, пропуски и ошибки, которые должны быть идентифицированы и устранены в процессе предварительной обработки данных.

Сырые данные из различных систем веб-аналитики могут иметь разные форматы и структуры. Это может затруднять сравнение и интеграцию данных из разных источников.

Обработка и анализ таких данных может быть времязатратным и трудоемким процессом. В зависимости от объема и сложности данных, предварительная обработка, очистка, трансформация и анализ могут занимать значительное количество времени и усилий со стороны аналитика. Это может отвлекать специалиста от выполнения более высокоуровневых задач, связанных с улучшением продукта или принятием стратегических решений. Однако, успешная работа с сырыми данными позволяет компаниям получать ценные инсайты и информацию, которые могут способствовать росту бизнеса, улучшению продуктов и повышению конкурентоспособности.

С учетом всех проблем и особенностей работы с сырыми данными из систем веб-аналитики важно признать, что качественный анализ данных является ключевым фактором успеха для любой современной организации. Непрерывное развитие компетенций аналитика, внедрение автоматизированных инструментов и алгоритмов, а также улучшение процессов обработки и анализа данных могут значительно упростить этот процесс и обеспечить компаниям стратегическое преимущество на рынке.

1.4 Обзор решений для автоматизации интерпретации данных

Важным компонентом в системе принятия решений на основе данных, а также их интерпретации, являются BI (Business Intelligence) решения. Эти инструменты представляют собой комплексные системы, которые собирают,

интегрируют, анализируют и визуализируют бизнес-данные в удобной и легко интерпретируемой форме. Они позволяют аналитикам визуализировать сложные данные, выявлять в них тренды и закономерности, а также использовать эти знания для принятия обоснованных аналитических решений. На современном рынке существует множество BI решений с различными функциональными возможностями. Следующий обзор BI систем даст подробное представление о ключевых инструментах в этой области, их особенностях и преимуществах для бизнеса и аналитики данных.

1.4.1 Microsoft Power BI

Microsoft Power BI является интегрированной платформой бизнес-аналитики, предоставляет обширный набор функций для анализа и визуализации данных.

Автоматическая интерпретация данных в Power BI доступна через функцию «Разведка данных» (Data Exploration), которая позволяет использовать алгоритмы машинного обучения для выявления закономерностей и трендов в данных. Пользователи могут применять различные модели машинного обучения, такие как регрессия, классификация и кластеризация, для автоматической интерпретации табличных данных. Встроенные возможности и интеграция с другими инструментами Microsoft, такими как Azure Machine Learning, позволяют пользователю применять машинное обучение без необходимости создания собственных моделей [8].

Плюсы:

- Интуитивный и мощный интерфейс
- Интеграция с множеством источников данных
- Богатые возможности аналитики и визуализации
- Встроенный функционал автоматической интерпретации данных и машинного обучения

Минусы:

- Сложность освоения для новичков
- Не является решением с открытым исходным кодом

- Возможные ограничения в настройке и стоимости

1.4.2 Tableau

Популярная платформа аналитики и визуализации данных, предоставляющая пользователям множество инструментов для создания дашбордов и отчетов. Tableau поддерживает интеграцию с различными источниками данных и предлагает возможности встраивания аналитики на веб-страницы.

Автоматическая интерпретация данных в Tableau реализована через функцию «Текущие тренды» (Trending), которая позволяет пользователям автоматически выявлять тренды и закономерности в данных на основе алгоритмов машинного обучения. Также Tableau поддерживает интеграцию с платформами машинного обучения, такими как R и Python, что позволяет использовать дополнительные модели машинного обучения для автоматической интерпретации табличных данных. Тем не менее, интеграция с внешними системами машинного обучения может потребовать дополнительных усилий и знаний со стороны пользователей [9].

Плюсы:

- Интуитивный интерфейс
- Широкий выбор инструментов аналитики и визуализации
- Интеграция с разнообразными источниками данных
- Поддержка внешних платформ машинного обучения

Минусы:

- Относительно высокая стоимость
- Сложность интеграции с внешними системами машинного обучения
- Ограниченный функционал автоматической интерпретации данных встроенными средствами

1.4.3 Google Data Studio

Платформа аналитики и визуализации данных, которая легко интегрируется с другими сервисами Google и поддерживает широкий спектр источников данных. Data Studio бесплатен для использования и обеспечивает

быстрое развертывание и настройку, что делает его привлекательным решением для пользователей с ограниченным опытом работы с аналитикой данных.

Однако автоматическая интерпретация данных в Google Data Studio ограничена. Возможности машинного обучения доступны через интеграцию с Google Cloud AI Platform и Google BigQuery ML, но требуют создания пользовательских моделей и знаний со стороны аналитика. Использование этих сервисов может также повлечь дополнительные расходы [10].

Плюсы:

- Простота и интуитивность использования
- Бесплатное предоставление сервиса
- Интеграция с сервисами Google и различными источниками данных

Минусы:

- Ограниченный функционал автоматической интерпретации данных и машинного обучения
- Требования к знаниям и умениям для интеграции с внешними системами машинного обучения
- Возможные дополнительные затраты при использовании внешних сервисов машинного обучения

1.4.4 QlikSense

Платформа для визуализации данных и бизнес-аналитики, предоставляющая пользователям интуитивно понятный интерфейс для создания интерактивных дашбордов и отчетов. QlikSense использует ассоциативный движок для анализа данных, что позволяет искать скрытые зависимости и взаимосвязи [11].

Плюсы:

- Интуитивный интерфейс и drag-and-drop функциональность
- Ассоциативный движок для анализа данных
- Интеграция с различными источниками данных

- Масштабируемость и возможность работы с большими объемами данных
- Расширяемость с помощью сторонних расширений и API

Минусы:

- Может быть сложным для начинающих пользователей без предварительной подготовки
- Лицензирование и стоимость могут быть высокими для небольших компаний
- Автоматическая интерпретация данных ограничена и зависит от использования дополнительных расширений и интеграций

1.4.5 Yandex DataLens

Облачный инструмент для визуализации данных и бизнес-аналитики от компании Яндекс. DataLens позволяет создавать интерактивные дашборды, анализировать данные с помощью встроенных функций и визуализаций, а также интегрироваться с другими продуктами Яндекса, такими как Яндекс.Метрика. Подходит для быстрого создания несложных отчетов. ETL-преобразования необходимо выполнять на уровне СУБД, в то время как создание расчетных мер можно делать на стороне BI-платформы. Возможности для автоматического поиска зависимостей отсутствуют [12].

Плюсы:

- Простота использования и интуитивно понятный интерфейс
- Интеграция с продуктами Яндекса, такими как Яндекс.Метрика и Яндекс.Облако
- Облачная архитектура, не требующая установки программного обеспечения на локальных компьютерах
- Поддержка SQL-запросов для гибкого анализа данных
- Встроенные функции анализа временных рядов и прогнозирования

Минусы:

- Ограниченная функциональность в сравнении с некоторыми конкурирующими продуктами

- Зависимость от интернет-соединения из-за облачной архитектуры
- Автоматическая интерпретация данных ограничена, основной фокус на визуализации

1.4.6 Российские BI-системы

Российские BI-системы развивались иначе, чем мировые лидеры, с акцентом на дополнение и расширение иностранных платформ функционалом, актуальным для российского рынка. Так, они часто предоставляют функции write-back, визуализацию иерархических деревьев и графов. С другим стартом и финансированием, от российских BI-систем не стоит ждать полной замены западных решений. Однако рынок развивается быстро, с обновлениями платформ и изменяющейся картиной рынка [13].

1.5 Вывод

Несмотря на разнообразие инструментов для анализа и визуализации данных, таких как Power BI, DataLens, QlikSense, DataStudio и Tableau, функциональность этих систем не всегда является достаточной для автоматической интерпретации больших объемов данных. Рассмотрим основные ограничения этих систем, которые могут затруднить автоматическую интерпретацию данных и поиск гипотез.

Во-первых, большинство из этих инструментов сосредоточены на визуализации данных и предоставлении аналитику интуитивно понятных интерфейсов для изучения данных. В то же время, они обладают ограниченным функционалом по автоматическому поиску и интерпретации зависимостей в табличных данных, что заставляет аналитика тратить много времени на ручной анализ.

Во-вторых, системы, такие как Power BI, QlikSense и Tableau, хотя и обладают встроенными возможностями анализа временных рядов и машинного обучения, часто требуют дополнительной настройки и интеграции с другими сервисами для полноценного использования автоматической интерпретации данных. Это может быть сложным и трудоемким процессом, особенно для начинающих аналитиков.

Третья проблема касается доступности данных для анализа. Некоторые из этих систем, такие как DataLens и DataStudio, зависят от собственных решений их компаний.

Четвертая проблема заключается в том, что инструменты аналитики, такие как Power BI, DataLens, QlikSense, DataStudio и Tableau, в основном предлагают статические визуализации и отчеты, что может снизить эффективность автоматической интерпретации данных и поиска гипотез, так как аналитик должен переключаться между различными представлениями данных и самостоятельно определять возможные зависимости.

Пятая проблема связана с индивидуальными особенностями каждой системы аналитики. Каждый инструмент имеет свои собственные плюсы и минусы, что может затруднить выбор оптимального инструмента для автоматической интерпретации данных. Аналитики могут оказаться перед сложным выбором, учитывая разнообразие возможностей и недостатков каждой системы.

Шестая проблема связана с тем, что автоматическая интерпретация данных требует развития методов машинного обучения и статистического анализа, которые часто не являются основным фокусом коммерческих инструментов аналитики. Это может привести к тому, что аналитикам придется разрабатывать собственные алгоритмы или интегрировать сторонние библиотеки для автоматического анализа данных.

Седьмая проблема – ограничения самих систем. Если аналитик проводит анализ в одной из систем ему сложно мигрировать результаты или часть датасета в другую систему или даже в jupyter notebook для более гибкой работы. Тем самым работа с одной конкретной системой накладывает ограничение той экосистемы, в которой она находится.

В итоге, несмотря на широкий спектр инструментов аналитики данных, таких как Power BI, DataLens, QlikSense, DataStudio и Tableau, существующий функционал этих систем часто оказывается недостаточным для автоматической интерпретации больших объемов данных и поиска гипотез.

из-за этого аналитики вынуждены тратить много времени на ручной анализ данных, что снижает эффективность их работы и замедляет процесс принятия решений.

Для решения этой проблемы необходимо разработать систему, способную автоматически анализировать и интерпретировать табличные данные, выявлять важные зависимости и формировать гипотезы на основе результатов анализа. Это поможет существенно облегчить процесс анализа данных, уменьшить время, затрачиваемое на поиск и интерпретацию гипотез, а также снизить вероятность ошибок, связанных с человеческим фактором.

Использование автоматической интерпретации данных также поможет решить проблему недостатка квалифицированных специалистов в области аналитики. При наличии эффективных автоматических систем, даже менее опытные аналитики смогут успешно выполнять свою работу и делать значимые выводы из данных, что повысит общую производительность команды и ускорит процесс принятия решений.

Таким образом, для решения проблемы недостаточного функционала существующих систем аналитики в автоматической интерпретации больших объемов данных и поиске гипотез, следует разработать новые инструменты и методы, а также интегрировать уже существующие алгоритмы машинного обучения и статистического анализа. Создание и внедрение автоматических систем для интерпретации табличных данных из веб-аналитики обеспечит более быстрый и точный анализ данных, что, в свою очередь, позволит аналитикам сосредоточиться на более сложных и важных аспектах своей работы и принимать более обоснованные и эффективные решения по развитию продукта.

Глава 2. Датасет и инструменты для анализа

2.1 Базовые данные систем веб аналитики.

Хотя для разработки и будет использован конкретный датасет, в результате работы должен получиться гибкий инструмент, который бы позволил работать с данными из разных систем аналитики. А учитывая схожесть структуры основных данных, главной задачей видится как раз унификация и определения минимально необходимого списка полей для реализации задачи.

Системы веб-аналитики собирают обширные данные о действиях пользователей на сайтах и в приложениях, предоставляя аналитику основу для анализа и оптимизации продукта. Типичные сырые данные из таких систем включают разнообразные столбцы и характеристики. Но в основном все системы аналитики, которые используют события для трекинга действий пользователя имеют общие базовые данные, такие как:

User ID (Идентификатор пользователя): Уникальный идентификатор, присваиваемый каждому пользователю. Он может быть представлен в виде целого числа, строки или хеша и используется для атрибуции действий к конкретному пользователю.

Session ID (Идентификатор сеанса): Уникальный идентификатор, присваиваемый каждому сеансу взаимодействия пользователя с продуктом. Что позволяет определить продолжительность и частоту сеансов, а также связанные с ними действия. Как правило имеет искусственные ограничения по продолжительности, обычно около 30 минут от начал сеанса или последнего действия.

Timestamp (Временная метка): Дата и время, когда пользователь совершил определенное действие. Временные метки обычно хранятся в формате даты и времени (например, YYYY-MM-DD HH:MM:SS) и используются для определения периодичности и порядка действий.

Event (Событие): Тип действия, совершенного пользователем, такой как просмотр страницы, клик по ссылке, заполнение формы, покупка товара и

т.д. События могут быть представлены в виде строковых значений или категорий, цифр или идентификаторов. Используются для отслеживания взаимодействия пользователя с важными элементами интерфейса или для фиксирования достижений пользователем определенных результатов (например, время до первого взаимодействия с контентом – FID)

Page URL (URL страницы): Адрес страницы, на которой пользователь совершил определенное действие. URL может быть представлен в виде строки и используется для определения страницы, на которой произошло действие. В мобильных приложениях обычно используются ее аналоги, например такие как state, которые показывают шаг воронки или тип интерфейса с которым взаимодействует пользователь.

Referrer (Реферер): Источник трафика пользователя, такой как поисковый движок, рекламная кампания, социальные сети и т.д. Рефереры могут быть представлены в виде строковых значений или категорий и используются для определения эффективности различных маркетинговых каналов и стратегий привл

Device Information (Информация об устройстве): Данные о типе устройства пользователя, такого как мобильный, настольный или планшет, а также информация о бренде и модели устройства. Обычно используется для отслеживания качества версионирования приложения в зависимости от типа платформы.

Product ID (ID продукта): Уникальный идентификатор продукта с которым взаимодействует пользователь. Обычно в Аналитике SAAS продуктов – важный показатель, т.к. даже один и тот же изначальный продукт может иметь значительные отличия в зависимости от требований фактического пользователя.

Revenue (Выручка): Сумма денег, полученная от определенного действия пользователя, такого как покупка продукта. Это может помочь аналитикам понять, какие действия приносят наибольший доход и как оптимизировать стратегию монетизации.

Custom Variables (Пользовательские переменные): Дополнительные данные, которые могут быть определены в зависимости от специфических потребностей анализа. Это могут быть демографические данные, данные о поведении, информация о маркетинговой кампании и т.д.

2.2 Датасет используемый в работе

Для работы были взяты реальные данные компании, которая занимается разработкой программного обеспечения в сфере транзакций в игровой индустрии. Ее продукт – платформа, которая предоставляется игровым разработчикам. Они могут встроить ее на последние этапы оплаты внутри своих продуктов. Пользователь в этом случае бесшовно попадет на интерфейс, в котором может выбрать из сотен способов оплаты необходимый для него и совершить оплату. Такое решение помогает командам разработчиков не содержать штат для интеграции с сотнями систем, отслеживании регионального законодательства каждой из 180 стран и не разбираться в нюансах налогообложения.

Данные представляют из себе сырые данные (raw data) из внутренней системы аналитики за май и июнь 2021 года. Процесс сбора данных начинается с момента, когда пользователь впервые взаимодействует с платежным инструментом. В этот момент система веб-аналитики начинает отслеживать действия пользователя и сохраняет эти данные для дальнейшего анализа. В процессе этого действия фиксируется уникальный идентификатор пользователя (User ID), который будет использован для связи всех последующих действий с этим конкретным пользователем. Каждое действие или событие, которое происходит во время взаимодействия пользователя с продуктом, регистрируется и сохраняется в виде отдельной записи в базе данных.

Когда пользователь начинает взаимодействовать с платежным инструментом, каждое его действие (action) регистрируется. Это может включать в себя выбор платежного метода, выбор страны платежа, взаимодействие формами (например с формой GDPR или ввода данных о

банковской карте). Каждое такое действие записывается как отдельное событие, где заполнены все остальные поля. В каждой записи также фиксируется время (Timestamp), когда произошло событие.

Когда пользователь решает совершить транзакцию и переходит к оплате, фиксируется все необходимые события для отслеживания пути пользователя. Здесь важно отметить, что из соображений безопасности и конфиденциальности никакие платежные данные, такие как номера карт, идентификаторы кошельков, фамилию и имя, не хранятся в системе веб-аналитики. Однако, полностью фиксируются все необходимые обезличенные данные, такие как тип выбранного платежного метода (payment id) и уникальный идентификатор транзакции (purchase id).

После совершения транзакции, система регистрирует событие покупки. В этом случае, в запись будет включен уникальный идентификатор проекта, в котором производилась оплата и в который будет начислена приобретаемые виртуальная вещь или валюта (project ID), а также сумма транзакции (sales) и размер вознаграждения агента за проведенную транзакцию (revenue). Это позволяет проследить, какие продукты или услуги наиболее популярны среди пользователей, а также оценить общую выручку от продаж.

Все эти данные, собранные во время сессии пользователя, сохраняются и структурируются для дальнейшего анализа. Используя эти данные, можно изучать поведение пользователей, их предпочтения, понимать, какие элементы платежного интерфейса наиболее привлекательны, а какие вызывают трудности или отторжение.

Особо стоит отметить, что хоть данные и были взяты из системы аналитики как есть (AS IS), они были подвергнуты некоторым изменениям для сохранения коммерческой информации. Были изменены все идентификаторы пользователей и проектов, с сохранением числа и распределения, был изменен именно порядок номеров. Были изменены показатели sales и revenue с сохранением распределения.

2.3 Инструменты для решения задачи

Ключевым языком программирования, который активно используется в сфере анализа данных и машинного обучения, является Python. Он предоставляет обширный набор библиотек для работы с данными, что делает его универсальным инструментом для аналитиков. Специфические возможности Python, а также его библиотек, наиболее актуальны для данного исследования, поскольку они способны существенно упростить процесс обработки и анализа больших объемов данных, полученных из систем веб-аналитики.

Дополнительно, будут использованы такие библиотеки как Pandas, интегрированная в Python, предоставляет средства для удобной и эффективной работы с табличными данными, включая функциональность по обработке, очистке и агрегации данных. Scikit-learn, позволяет разрабатывать и оптимизировать модели машинного обучения, что будет необходимо для выявления важных зависимостей в данных и автоматизации интерпретации. Retentioneering предоставляет возможности для анализа поведения пользователей.

При выполнении данного исследования, наиболее актуальными инструментами становятся библиотеки, направленные на интерпретацию результатов машинного обучения. Так, CatBoost способствует эффективному обучению моделей на больших данных, в то время как LIME, DTreeViz и ELI5 упрощают процесс визуализации и интерпретации результатов, что важно для понимания полученных зависимостей и формирования основанных на них бизнес-решений.

В исследовании будут представлены наиболее популярные и полезные инструменты, которые помогут улучшить качество и эффективность работы с данными. Разберем их подробнее.

1. Python

Python – это высокоуровневый, многоцелевой язык программирования с открытым исходным кодом. Он отличается простотой и лаконичностью

синтаксиса, что облегчает чтение и написание кода. Благодаря своей универсальности и большому количеству доступных библиотек, Python стал одним из основных языков программирования, используемых в научных исследованиях, аналитике данных и машинном обучении. В этом исследовании Python будет основным языком программирования для автоматизации процесса анализа данных.

2. Pandas

Pandas – это одна из наиболее популярных библиотек для обработки и анализа данных на Python. Она предоставляет удобные структуры данных, такие как DataFrame и Series, и мощные инструменты для работы с табличными данными. Pandas позволяет выполнять различные операции над данными, такие как очистка, фильтрация, агрегирование, трансформация и визуализация. В данной работе Pandas будет использоваться для подготовки, обработки и анализа табличных данных из систем веб-аналитики [14].

3. Scikit-learn

Scikit-learn – это открытая библиотека для машинного обучения на Python. Она предоставляет простые и эффективные инструменты для обработки данных, включая алгоритмы классификации, регрессии, кластеризации и понижения размерности. Scikit-learn также предлагает механизмы для оценки производительности моделей, валидации и оптимизации гиперпараметров. В контексте этого исследования Scikit-learn будет использоваться для реализации алгоритмов машинного обучения, связанных с автоматической интерпретацией табличных данных и выявлением важных зависимостей между переменными [15].

4. Retentioneering

Retentioneering – это фреймворк на основе Python, разработанный для анализа и оптимизации пользовательского взаимодействия с веб-сайтами и приложениями. Retentioneering предоставляет инструменты для изучения и визуализации пользовательских траекторий, выявления аномалий и влияния различных факторов на удержание пользователей. В рамках данного

исследования Retentioneering будет использован для анализа поведения пользователей и выявления потенциальных возможностей для оптимизации [16].

5. CatBoost

CatBoost – это библиотека машинного обучения с открытым исходным кодом. Она предлагает высокопроизводительные алгоритмы градиентного бустинга, оптимизированные для работы с категориальными признаками. В исследовании CatBoost может быть использован для реализации алгоритмов машинного обучения, которые обеспечивают эффективную обработку категориальных данных и выявление сложных взаимосвязей между переменными. Будут использованы механизмы объяснения решений, такие как future importance [17].

6. LIME (Local Interpretable Model-agnostic Explanations)

LIME – это библиотека для интерпретации прогнозов машинного обучения, независимая от конкретной модели. Она предоставляет методы для объяснения отдельных прогнозов, исследуя их в локальном контексте. LIME помогает создать простые модели, которые аппроксимируют поведение сложных моделей машинного обучения в окрестности конкретного примера. LIME используется для улучшения интерпретируемости результатов машинного обучения и объяснения важности различных признаков [18].

7. DTreeViz

DTreeViz – это библиотека визуализации деревьев решений, разработанная для упрощения интерпретации и анализа моделей, основанных на деревьях решений. Она позволяет строить красочные и информативные графические изображения деревьев решений, которые помогают понять, как модель делает свои прогнозы и какие признаки являются наиболее важными для принятия решений. DTreeViz использован для визуализации деревьев решений, созданных с использованием алгоритмов машинного обучения, что облегчает интерпретацию результатов.

8. ELI5 (Explain Like I'm 5)

ELI5 – это библиотека для интерпретации и визуализации результатов машинного обучения, предоставляющая простые и понятные объяснения работы алгоритмов. Она поддерживает различные модели, включая деревья решений, линейные модели и ансамбли. В контексте исследования ELI5 использована для генерации интуитивно понятных и доступных объяснений результатов моделей машинного обучения [19].

Применение библиотек для интерпретации и визуализации результатов машинного обучения в задаче автоматической интерпретации табличных данных из систем веб-аналитики имеет решающее значение. Это связано с несколькими ключевыми факторами, которые влияют на процесс работы аналитика данных и обеспечивают успешную и эффективную оптимизацию продуктов.

Во-первых, позволит лучше понять сложные взаимосвязи между переменными. В реальной практике веб-аналитики данные могут быть очень сложными и содержать множество переменных, между которыми существуют разнообразные зависимости. Интерпретация и визуализация результатов машинного обучения позволяют аналитикам лучше понять эти сложные взаимосвязи, что облегчает процесс выявления важных факторов, влияющих на ключевые показатели продукта. Благодаря этому аналитики могут более точно определить, какие изменения в продукте могут привести к улучшению его качества и коммерческих показателей.

Во-вторых, упрощает интерпретацию результатов машинного обучения. Модели машинного обучения могут быть достаточно сложными и трудными для интерпретации, особенно если аналитики не обладают глубокими знаниями в области алгоритмов и методов машинного обучения. Библиотеки для интерпретации и визуализации результатов машинного обучения, такие как LIME и ELI5, позволяют преобразовывать результаты моделей в понятную и доступную форму, что облегчает их анализ и позволяет аналитикам быстрее и точнее принимать решения.

В-третьих, позволит обнаруживать новые закономерности и гипотезы. Библиотеки для интерпретации и визуализации результатов машинного обучения могут помочь аналитикам обнаружить новые закономерности и гипотезы, которые могут быть использованы для оптимизации продукта. Это особенно важно в условиях постоянно изменяющегося рынка, где быстрое принятие решений и адаптация к новым трендам могут стать ключевыми факторами успеха продукта.

В-четвертых, повысит эффективность работы аналитика. Использование библиотек для интерпретации и визуализации результатов машинного обучения позволяет аналитикам сократить время, необходимое для анализа данных и выявления важных зависимостей. Вместо того чтобы тратить драгоценное время на поиск и интерпретацию данных вручную, аналитики могут использовать эти инструменты для автоматического поиска гипотез и определения ключевых факторов, которые могут быть использованы для улучшения продукта. Это ускоряет процесс принятия решений и позволяет аналитикам сосредоточиться на других важных аспектах своей работы, таких как стратегия развития продукта и его оптимизация.

В-пятых, улучшит качество аналитических выводов. Библиотеки для интерпретации и визуализации результатов машинного обучения позволяют аналитикам представлять результаты своих исследований в более ясной и понятной форме, что в свою очередь может способствовать повышению качества аналитических выводов. При использовании этих инструментов аналитики могут выявить скрытые закономерности и сложные взаимосвязи между переменными, что обеспечивает более точное понимание факторов, влияющих на ключевые показатели продукта. Это, в свою очередь, позволяет аналитикам принимать более обоснованные и эффективные решения по развитию продукта и его оптимизации.

Применение библиотек для интерпретации и визуализации результатов машинного обучения играет важную роль в задаче автоматической интерпретации табличных данных из систем веб-аналитики. Эти инструменты

позволяют лучше понимать сложные взаимосвязи между переменными, упрощают интерпретацию результатов машинного обучения, обеспечивают воспроизводимость исследований и способствуют повышению эффективности работы с данными.

2.4 Алгоритмы машинного обучения использованные в работе

Машинное обучение – это широкая и разнообразная область исследований, которая включает множество различных алгоритмов, каждый из которых имеет свои особенности и применение. В контексте работы особый интерес представляют алгоритмы классификации и кластеризации. Они позволяют выявлять в данных важные закономерности и зависимости, что может быть использовано для повышения эффективности и качества анализа данных в системах веб-аналитики.

Классификация – это задача машинного обучения, которая заключается в отнесении объекта к одной из predetermined категорий на основе его признаков. Алгоритмы классификации обучаются на основе обучающего набора данных, в котором каждому объекту присваивается определенная метка или класс. После обучения алгоритм может применяться для классификации новых объектов.

Одним из наиболее распространенных и эффективных алгоритмов классификации являются деревья решений. Эти алгоритмы строят модель принятия решений в виде дерева, где каждый узел представляет собой тест на определенный признак, а ветви – возможные исходы этого теста. Основным преимуществом деревьев решений заключается в их интерпретируемости: они позволяют легко понять, какие признаки и как влияют на принимаемое решение.

Еще одним важным алгоритмом классификации является градиентный бустинг, который использует ансамбль слабых моделей (обычно деревьев решений), чтобы создать более сильную модель. Градиентный бустинг работает путем последовательного добавления новых моделей, каждая из которых пытается исправить ошибки предыдущих. В работе градиентный

бустинг использован для выявления сложных зависимостей в данных и повышения точности прогнозов.

Кластеризация – это другая важная задача машинного обучения, которая заключается в группировке объектов на основе их сходства. В отличие от классификации, в задаче кластеризации нет заранее определенных классов, и алгоритму необходимо самостоятельно определить структуру данных, выявив группы (кластеры) похожих объектов. Поскольку веб-аналитика часто работает с неструктурированными или полуструктурированными данными, кластеризация может быть особенно полезна для выявления в данных скрытых закономерностей и групп.

Одним из наиболее известных и простых в применении алгоритмов кластеризации является алгоритм К-средних. Он основан на минимизации суммы квадратов расстояний от объектов до центров их кластеров. Кратко алгоритм можно описать так: алгоритм выбирает К случайных центров кластеров, затем каждый объект относим к тому кластеру, центр которого ближе всего к нему, после чего пересчитываем центры кластеров как среднее арифметическое всех объектов в кластере и повторяем процесс до тех пор, пока центры кластеров не перестанут существенно меняться.

Есть и другие алгоритмы кластеризации, такие как DBSCAN или иерархическая кластеризация, которые могут быть более эффективными для некоторых типов данных. Однако, они часто требуют больше времени для обучения и могут быть более сложными в интерпретации, что делает их менее подходящими для задачи. Кроме того, эти алгоритмы могут быть менее эффективными при работе с большими объемами данных, поскольку они требуют больше вычислительных ресурсов и времени на обучение и предсказание.

Поэтому, алгоритм К-средних за свою простоту и эффективность, является оптимальным выбором для задач кластеризации в области веб-аналитики в контексте этой конкретной задачи. В частности, он показал себя более быстрым на больших объемах данных (миллионы кейсов), в то время

как эффективность и точность падала не критически сильно. А в поставленной задаче «экстремальная» точность не так важна как быстроедействие.

Итак, для задачи автоматической интерпретации табличных данных из систем веб-аналитики наиболее подходящими являются алгоритмы классификации и кластеризации, в частности деревья решений, градиентный бустинг и К-средних. Они позволяют эффективно анализировать большие объемы данных, выявлять важные закономерности и классифицировать пользователей на основе их поведения.

Деревья решений и градиентный бустинг позволяют классифицировать пользователей, предсказывать их поведение и, таким образом, оптимизировать взаимодействие с ними. В контексте решаемой задачи, это может помочь определить, какие пользователи склонны к определенному виду поведения, например, к совершению покупки, и тем самым позволить сосредоточить усилия на тех пользователях, которые наиболее вероятно принесут наибольшую выгоду.

С другой стороны, К-средних позволяет нам группировать пользователей на основе их сходства, что может быть полезно для выявления групп пользователей с похожим поведением. Это может помочь лучше понять структуру представленной аудитории и разработать более эффективные стратегии взаимодействия с каждой из групп.

Таким образом, алгоритмы машинного обучения играют ключевую роль в автоматизации анализа табличных данных из систем веб-аналитики. Они позволяют улучшить эффективность и качество анализа данных, выявлять важные закономерности и предсказывать поведение пользователей. Однако, выбор конкретного алгоритма должен основываться на тщательном анализе данных и учете специфики задачи.

2.5 Этические аспекты

Этические вопросы, связанные машинного обучения, являются объектом глубокого изучения и обсуждения в современном мире. С одной стороны, автоматизация аналитических процессов предлагает обширные

возможности для оптимизации работы с данными, принятия более качественных решений и улучшения результатов работы. С другой стороны, использование этих технологий неизбежно сталкивается с рядом этических вызовов и проблем, которые нужно решать.

Одним из главных вопросов является проблема приватности данных. Многие системы веб-аналитики собирают и анализируют личные данные пользователей, включая информацию о поведении, предпочтениях, демографических характеристиках и даже геолокации [20]. Это вызывает вопросы о конфиденциальности и защите личных данных, и ставит важную задачу обеспечения соответствия процессов анализа данных законодательству и нормам в области защиты данных. Особенно актуальным этот вопрос стал в последнее время, когда даже у крупных компаний возникают проблемы с сохранностью персональных данных.

Связанная с этим проблема – вопрос соблюдения принципа справедливости при использовании машинного обучения. Модели машинного обучения могут формировать выводы и предсказания на основе анализа данных, которые могут быть смещенными или неполными. Это может привести к неравноправию, дискриминации или неправильному принятию решений, что является серьезным этическим нарушением [21]. Например если в изначальной выборке данных подавляющее большинство пользователей относятся к одной конкретной социальной группе. В этом случае ответы и автоматически-сформированные гипотезы будут смещены в сторону этой группы, просто по численному признаку. Аналитик, при анализе данных всегда должен учитывать особенность используемого датасета и при необходимости делать поправки.

Важным аспектом использования машинного обучения и автоматической интерпретации данных в системах веб-аналитики является уважение к личной жизни пользователей и их данных [22]. Это включает в себя обеспечение конфиденциальности и безопасности данных, а также учет предпочтений и прав пользователей в отношении их данных. Важно помнить,

что данные, полученные от пользователей, должны быть использованы ответственно и с учетом их прав и ожиданий.

Этические вопросы, связанные с использованием автоматической интерпретации данных и машинного обучения, требуют дальнейшего изучения и обсуждения. Они представляют собой важную составляющую в развитии веб-аналитики и требуют совместных усилий со стороны исследователей, разработчиков, пользователей и регуляторов. Чем более ответственно мы подойдем к этим вопросам, тем более эффективно и безопасно сможем использовать возможности, которые предоставляют нам автоматизация и машинное обучение.

2.6 Вывод

Автоматическая интерпретация табличных данных из систем веб-аналитики является сложной и многогранной задачей, требующей глубокого понимания не только структуры данных, но и методологии их обработки и анализа. Вторая глава данной работы призвана заполнить этот пробел, описывая ключевые аспекты этой задачи в деталях.

Базовые данные из систем веб-аналитики являются основой для любого анализа и интерпретации. Они содержат информацию о пользовательском взаимодействии с продуктом, такую как источник перехода, действия пользователя, его история транзакций и пр. Эта информация имеет ценное значение для аналитиков, так как она позволяет определить общий профиль пользователя, его предпочтения и поведение. Понимание структуры и содержания этих данных является первым шагом к их эффективной обработке и анализу.

Для решения задачи автоматической интерпретации табличных данных был представлен набор инструментов, включающий в себя язык программирования Python и библиотеки Pandas, Scikit-learn, Retentioneering, CatBoost, LIME, DTreeViz и ELI5. Эти инструменты были выбраны на основе их функциональности, гибкости и простоты использования, и они позволяют

выполнить все этапы обработки данных, от их очистки и предобработки до моделирования и визуализации результатов.

При выборе подходящих алгоритмов машинного обучения для решения задачи автоматической интерпретации табличных данных особое внимание было уделено деревьям решений, методу градиентного бустинга и алгоритму кластеризации K-средних. Эти алгоритмы были выбраны на основе их эффективности, скорости вычислений и способности выявлять сложные зависимости в данных.

Однако использование машинного обучения для автоматической интерпретации табличных данных не ограничивается техническими аспектами. Этические вопросы также играют важную роль. Конфиденциальность данных, прозрачность и объяснимость алгоритмов, а также ответственность за принимаемые на основе анализа данных решения, являются критическими аспектами, которые должны быть учтены при проектировании и внедрении систем автоматической интерпретации табличных данных.

С точки зрения конфиденциальности, важно гарантировать, что данные, использованные в процессе анализа, обрабатываются в соответствии с применимыми законами о защите данных и что индивидуальная приватность пользователей защищена. Это включает в себя использование анонимизации и псевдонимизации, а также обеспечение того, что данные используются только для целей, с которыми пользователи согласились.

Прозрачность и объяснимость алгоритмов также являются ключевыми. Это означает, что должна быть возможность объяснить, как алгоритм работает и как он принимает решения. Инструменты визуализации и интерпретации, такие как LIME, DTreeViz и ELI5, играют здесь ключевую роль, позволяя аналитикам и другим заинтересованным сторонам понять, как алгоритмы машинного обучения работают и какие выводы они делают на основе данных.

Наконец, ответственность за принимаемые на основе анализа данных решения должна быть четко определена. В то время как машины могут

автоматизировать большую часть процесса анализа данных, в конечном итоге люди несут ответственность за интерпретацию и использование результатов этого анализа.

В целом, автоматическая интерпретация табличных данных из систем веб-аналитики с использованием машинного обучения является важным инструментом для улучшения эффективности и качества работы аналитика данных. Она обеспечивает существенное улучшение процесса анализа данных, позволяя аналитикам сосредоточиться на формировании стратегий и решений для улучшения продукта и достижения более высоких результатов в своей работе. Но важно помнить, что вместе с этими преимуществами приходят и ответственности, которые необходимо серьезно учесть для этического использования данных и технологий машинного обучения.

3. Разработка программной реализации инструмента для автоматической интерпретации данных из систем веб аналитики.

3.1 Описание задачи

Для решения проблемы автоматической интерпретации данных из систем веб аналитики, в качестве основного инструмента разумно было бы использовать инструменты машинного обучения.

Это обусловлено рядом преимуществ, которые машинное обучение может предложить в контексте подобной работы. Во-первых, машинное обучение позволяет анализировать большие объемы данных, что является актуальной проблемой в области веб-аналитики. Во-вторых, это позволяет выявить сложные закономерности и зависимости в данных, которые могут быть недоступны для статистических, экспертных и других видов анализа.

Необходимо будет изучить структуру представляемых данных, сделать из них необходимую выгрузку. После этого нужно будет протестировать несколько комбинаций методов машинного обучения, для выявления наиболее подходящих, исходя из условий задачи.

В частности, я начну с кластеризации, поскольку эта задача представляет собой отличную отправную точку для этой целей. Кластеризация является одной из самых распространенных задач машинного обучения и предполагает группировку данных на основе их сходства или различия. Кластеризация может помочь в идентификации групп пользователей с похожим поведением, на основе скрытых факторов и связей.

Цель работы заключается в создании набора инструментов для аналитика, основанных на использовании Google Colab или Jupyter nootbook развернутого на обычном домашнем компьютере, что является важным условием для оптимизации работы с данными. В дальнейшем для оценок производительности и скорости работы я ориентировался на бесплатную версию Google Colab. При выборе инструментов я уделял особое внимание необходимости обеспечения быстродействия системы, учитывая технические характеристики платформы Colab. Такой подход позволяет сократить время

ожидания и ускорить процесс анализа данных, что особенно важно в условиях работы с большими объемами информации и необходимостью быстрого принятия решений.

3.2 Сбор и подготовка данных

В процессе практической реализации любого аналитического исследования, связанного с данными веб аналитик, да и с любым другим большим объем данных, первостепенным является этап сбора и подготовки данных. Именно от него может зависеть успех анализа и именно на нем можно допустить самые критичные ошибки.

В данном случае, исходные данные для анализа хранились в системе Google BigQuery, в которую собираются данные из внутренней системы аналитики. Эти данные охватывали работу основного продукта компании за последние 10 лет и были связаны с различными аспектами работы продукта, что потребовало их детального изучения и внимательного подхода к сбору.

Первый этап работы заключался в выгрузке данных только по мобильным платформам и только по пользователям из России. Это требование было обусловлено задачами исследования и приоритетами компании. Однако, эта задача не была простой, так как данные содержали информацию о различных технических событиях, которые не имели отношение к уптп пользователя, а также данные, относящиеся к другим продуктам компании.

Следовательно, перед тем как приступить к анализу данных, нужно было тщательно изучить имеющуюся информацию и определить, какие данные являются релевантными. Это потребовало углубленного понимания бизнес-процессов и операций компании, а также знания о типах данных и форматах, которые используются в системах веб-аналитики.

По требованию компании, все идентификационные данные в выгрузке для исследования должны были быть зашифрованы, для обеспечения меньшей интерпретируемости в коммерческих целях, при этом научная ценность данных была полностью сохранена. Это было важным этапом, так как

обеспечение конфиденциальности и безопасности данных является критически важным аспектом при работе с коммерческими данными.

Следующим этапом работы было проведение исследовательского анализа данных (EDA) с использованием SQL. Это было наиболее простым решением, т.к. исходный датасет включал в себя 14 500 000 000 строк и решать это средствами Google colab было бы сложной задачей. В то время такие базы данных как Google BigQuery являются колоночными, данные в них хранятся и управляются на уровне столбцов, а не строк, как это обычно происходит в традиционных реляционных базах данных, что положительно сказывается на производительности и функциональности этих баз данных [23]. Для задач аналитики, а особенно для запросов, ориентированных на агрегацию и сканирование больших объемов данных, колоночные базы могут обеспечить значительное улучшение производительности и способны достаточно быстро обрабатывать большие объемы информации. Этот этап включал изучение структуры данных, их распределения, выявление потенциальных аномалий и искажений, а также определение ключевых переменных для дальнейшего анализа.

3.3. Разработка реализации

3.3.1 Кластеризация

Кластеризация является мощным инструментом в анализе данных, позволяющим проводить группировку схожих объектов. Этот процесс играет решающую роль в исследовании внутренних структур и зависимостей в данных, что позволяет обнаруживать скрытые образы и паттерны, которые при поверхностном анализе могут остаться незамеченными.

Наиболее широко используемым и легко интерпретируемым алгоритмом кластеризации является метод К-средних. Он представляет собой итеративный метод, целью которого является разделение набора n -мерных точек данных на k кластеров, где каждая точка принадлежит кластеру с ближайшим средним значением.

Для определения наиболее подходящего числа кластеров был использован метод «Elbow Rule», вместе с алгоритмом MiniBatchKmeans [24]. MiniBatchKMeans представляет собой вариацию алгоритма К-средних, которая использует «мини-пакеты» данных для уменьшения вычислительного времени, в то же время стремясь оптимизировать ту же целевую функцию. «Мини-пакеты» – это подмножества входных данных, которые случайным образом выбираются на каждой итерации обучения. Такие «мини-пакеты» существенно снижают объем вычислений, необходимых для сходимости к локальному решению. В отличие от других алгоритмов, которые ускоряют время сходимости К-средних, мини-пакет К-средних обычно дает результаты, которые лишь незначительно уступают стандартному алгоритму. Такой подход позволил весьма эффективно и быстро находить необходимое число кластеров даже в датасетах на миллионы кейсов.

Однако, в рамках всестороннего подхода к решению задачи, были рассмотрены и другие методы кластеризации, такие как DBSCAN, Спектральная кластеризация и Агломеративная иерархическая кластеризация.

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) – это алгоритм, который сформирован на основе плотности распределения

объектов. Он хорошо работает с данными, которые содержат кластеры различной формы и размера. Однако, в случае решаемой задачи этот алгоритм оказался слишком трудоемким, из-за чего время его выполнения становилось неприемлемо долгим [25].

Спектральная кластеризация – это алгоритм, который использует собственные векторы графа Лапласа для отображения данных, что позволяет применять стандартные алгоритмы кластеризации, такие как К-средних, в пространстве меньшей размерности [26]. Однако, несмотря на свою эффективность, данный метод также был отклонен в силу своей вычислительной сложности и длительного времени выполнения.

Агломеративная иерархическая кластеризация – это рекурсивный алгоритм, который объединяет наиболее близкие кластеры в единый кластер до тех пор, пока все данные не будут объединены в один кластер. Он позволяет представить данные в виде древовидной структуры, что упрощает интерпретацию. Однако, как и предыдущие методы, он был исключен из-за высокой вычислительной сложности и длительного времени выполнения.

OPTICS – имеет много общего с алгоритмом DBSCAN и можно считать его обобщением DBSCAN, где требование к параметру ϵ смягчается от фиксированного значения до диапазона значений. Основное отличие между DBSCAN и OPTICS в том, что OPTICS строит граф достижимости, назначая каждому образцу расстояние достижимости и позицию внутри атрибута порядка кластера. Они определяются при обучении модели и используются для определения принадлежности к кластеру [27].

Для того чтобы выбрать лучший алгоритм я оценил все алгоритмы по нескольким критериям: скорость, вычислительная сложность и интерпретируемость

Скорость – параметр оценивает время, которое требуется алгоритму для обучения на определенном наборе данных. Скорость является критическим параметром в больших или сложных наборах данных, где алгоритмы могут занимать значительное время для завершения обучения. Алгоритмы с высокой

скоростью обучения могут значительно сократить время, необходимое для анализа данных и принятия решений.

Вычислительная сложность – влияет на его масштабируемость и скорость работы. Алгоритмы с низкой вычислительной сложностью могут быстро обрабатывать большие наборы данных, в то время как алгоритмы с высокой вычислительной сложностью могут стать непригодными для обработки больших объемов данных из-за ограниченных вычислительных ресурсов и времени.

Интерпретируемость – параметр отражает, насколько легко человеку понять, как алгоритм работает и как он приходит к своим прогнозам. Важность интерпретируемости может варьироваться в зависимости от контекста: в некоторых случаях, например, когда результаты алгоритма используются для принятия важных решений, высокая интерпретируемость может быть очень ценной. В других случаях, особенно когда скорость или точность являются первостепенными, сложные алгоритмы, которые трудно интерпретировать, могут быть приемлемыми.

Следующая таблица иллюстрирует сравнение этих алгоритмов:

Алгоритм	Скорость выполнения	Вычислительная сложность	Интерпретируемость
К-средних	Высокая	$O(n)$ Низкая	Высокая
DBSCAN	Низкая	$O(n \log n)$ Высокая	Средняя
Spectral Clustering	Низкая	$O(n^3)$ Высокая	Средняя
OPTICS	Низкая	$O(n^2)$ Высокая	Средняя
Иерархическая	Низкая	$O(n^3)$ Высокая	Средняя

Таблица 1 – Сравнение методов кластеризации

В ходе исследования были применены и проанализированы различные методы кластеризации. Однако, основываясь на специфике решаемой задачи,

требуемых ресурсах, а также на ключевых метриках, таких как скорость выполнения, вычислительная сложность, интерпретируемость результатов было принято решение выбрать метод К-средних.

Метод К-средних был выбран, главным образом, из-за его скорости и простоты реализации, что было критически важно для проекта, основанного на использовании среды Colab [28]. Другие алгоритмы, хотя и демонстрировали сильные стороны, такие как устойчивость к шуму в DBSCAN или способность формировать сложные кластеры в спектральной кластеризации, оказались более ресурсоемкими и затратными с точки зрения времени исполнения, что делало их менее подходящими для данной задачи и условий проекта. Несмотря на то, что К-средних может быть не таким гибким, как другие алгоритмы по отношению к формам кластеров и шумам, его эффективность и непосредственная интерпретируемость делают его подходящим инструментом для начального этапа анализа данных. Кроме того, метод К-средних отличается хорошей масштабируемостью и может обрабатывать большие объемы данных, что является еще одним преимуществом в контексте веб-аналитики.




Рис 1 – пример распределения кластеров для трех самых популярных событий из датасета

Исходя из этого, можно сделать вывод о целесообразности использования метода К-средних в контексте данной работы.

3.3.2 Использование кластера в качестве целевого признака при классификации с помощью CatBoost

Последующий этап данного исследования включал глубокий анализ полученных кластеров. Подчеркнутое внимание было уделено ключевым показателям внутри каждого кластера, а именно: «Revenue per User» (RPU, выручка на пользователя) и «Conversion from Product Opening to Payment» (Конверсия от открытия продукта до оплаты). Этот анализ необходим был для

того, чтобы выявить существующие различия между кластерами по данным метрикам и выработать понимание динамики поведения пользователей внутри каждого кластера.

Cluster	Count	Sum	RPV, \$	CR, %
0	46426	24576	0.307414	0.529359
1	345	212	18.643879	0.614493
2	2950	2398	5.339685	0.812881
3	1	0	0.000000	0.000000
4	16624	15267	1.247624	0.91837

Таблица 2 – распределение основных метрик внутри кластеров

Исходя из этого анализа, было обнаружено, что кластеры демонстрируют заметные различия по обоим метрикам. Такое распределение свидетельствует о том, что метод кластеризации успешно выделил скрытые параметры различия в группах пользователей, которые отличаются по своим поведенческим паттернам и взаимодействием с продуктом.

Для того чтобы лучше интерпретировать различия между пользовательскими кластерами и определить ключевые факторы, влияющие на принадлежность пользователей к определенным кластерам, был применен алгоритм CatBoost [29]. CatBoost – это мощный алгоритм машинного обучения, разработанный специально для работы с категориальными данными, что делает его идеальным выбором для данной задачи.

Используя CatBoost, была обучена модель, предсказывающая номер кластера на основе характеристик пользователей и их поведения. После обучения модели был проведен анализ важности признаков (feature importance), который позволил увидеть, какие именно признаки оказывают наибольшее влияние на принадлежность пользователей к определенным кластерам.

Анализ важности признаков играет важную роль в интерпретации модели и понимании влияния каждого признака на прогнозируемый результат.

В данном случае, благодаря этому анализу, получилось идентифицировать основные события и характеристики пользователей, которые оказывают наибольшее влияние на принадлежность к определенному кластеру.




Рис 2 – Feature importance для предсказания номера кластера

Этот подход позволил не только выявить ключевые факторы, которые обуславливают различия между кластерами, но и понять, какие действия пользователей и их характеристики оказывают наибольшее влияние на конверсию и выручку. Благодаря этому получилось сформировать первые конкретные рекомендации по улучшению продукта и повышению его эффективности.

3.3.3 Eli5

В процессе обучения и интерпретации моделей машинного обучения была использована библиотека eli5. Eli5 – это библиотека Python,

предназначенная для разъяснения предсказаний моделей машинного обучения. Она предоставляет объяснения на основе «черного ящика», а также специальные реализации для некоторых моделей, например, алгоритмов логистической регрессии и случайного леса. В данной работе как раз использовались эти два алгоритма.

Логистическая регрессия – это статистический метод, используемый для создания модели, которая предсказывает вероятность бинарного исхода, основанного на одной или нескольких предикторных переменных. Она полезна для ситуаций, где нужно предсказать присутствие или отсутствие характеристики, основанной на наборе измерений или факторов.

Weight?	Feature
+6.095	create-invoice
+3.020	click-btn-pay
+2.702	open-status-success
+2.278	open-status
+2.019	open-payment-card-26
+1.501	enter-email
+1.188	open-payment
+0.984	open-status-return
+0.953	open-payment-balance
+0.867	show-error-failed-method
+0.807	open-status-fail
+0.761	invalid-zip
+0.712	show-email-field
+0.695	enter-phone
+0.597	open-account-delete-saved-methods
+0.490	open-
+0.490	scroll-ps-list
+0.442	open-account-save-payment-method-new-methods
+0.351	open-error
+0.351	show-error-page
... 20 more positive ...	
... 52 more negative ...	
-0.663	open-account-status-processing
-0.691	open-status-processing
-0.723	open-status-error
-0.817	open-payment-return
-1.161	click-show-more
-1.425	click-disallow-save-card
-1.605	change-status
-2.424	enter-zip
-2.527	open-account-status-success
-9.413	<BIAS>

Рис 3 – Вывод результата библиотекой Eli5 для логистической регрессии

Случайный лес, с другой стороны, – это модель машинного обучения, основанная на ансамбле решающих деревьев. Он создает множество таких деревьев и делает прогноз, усредняя прогнозы отдельных деревьев. Важно

отметить, что каждое дерево в ансамбле обучается независимо от остальных на подмножестве обучающих данных, выбранных случайным образом с заменой.

Weight	Feature
0.1246 ± 0.1168	create-invoice
0.1053 ± 0.2915	open-status-success
0.0894 ± 0.2195	change-status
0.0873 ± 0.2570	open-status-processing
0.0837 ± 0.2671	open-payment-return
0.0717 ± 0.1532	open-paystation
0.0615 ± 0.0530	open-payment
0.0574 ± 0.1635	enter-phone
0.0477 ± 0.1708	open-status
0.0389 ± 0.0677	click-btn-pay
0.0264 ± 0.0214	click-btn-return-url
0.0241 ± 0.0312	show-error-message
0.0204 ± 0.0230	open-savedmethod
0.0194 ± 0.0351	choose-method-header
0.0176 ± 0.0321	enter-email
0.0155 ± 0.0331	show-email-field
0.0141 ± 0.0338	open-status-processing-error
0.0134 ± 0.0172	open-payment-balance
0.0126 ± 0.0269	open-status-error
0.0072 ± 0.0165	enter-cardholder
... 83 more ...	

Рис 4 – Вывод результата библиотекой Eli5 для случайного леса

В контексте решаемой задачи, эти два алгоритма были использованы для выявления важности признаков на основе данных из системы веб-аналитики компании. Применение библиотеки eli5 позволило извлечь и интерпретировать значимость признаков, что помогло выявить ключевые факторы, влияющие на поведение пользователей.

Однако, хотя использование eli5 с логистической регрессией и случайным лесом дало некоторые полезные инсайты, было обнаружено, что эти модели не всегда выявляли одни и те же признаки. Это подчеркнуло важность использования различных подходов к изучению важности признаков.

Следующий шаг в исследовании включал использование Permutation Importance – метода, который оценивает важность признаков, переставляя значения признака и измеряя влияние этого на точность предсказания модели.

В данном случае, Permutation Importance был применен к моделям логистической регрессии и случайного леса [30].

Результаты, полученные с использованием Permutation Importance, оказались более важными, чем простым способом извлечения важности признаков. Это можно объяснить тем, что Permutation Importance учитывает как прямое влияние признака на целевую переменную, так и его взаимодействие с другими признаками. Это делает Permutation Importance более надежным инструментом для определения важности признаков, особенно в сложных и высокоразмерных наборах данных.

На основании полученных результатов можно сделать вывод о значительной эффективности Permutation Importance для определения важности признаков. Однако, существует потребность в дальнейшем применении этого метода к более сложным моделям, таким как нейронные сети, которые способны устанавливать более сложные и скрытые зависимости между признаками. Это может помочь в дальнейшем раскрытии скрытых структур и закономерностей в данных и привести к более точным и информативным прогнозам.

3.3.4 Извлечение ключевых факторов влияния из нейронной сети.

Анализируя подход к построению модели нейронной сети в контексте данного исследования, можно заметить применение методологии, основанной на гибкости и надежности, что является крайне важным при работе с веб-аналитикой. В конкретной задаче использовалась архитектура, включающая полносвязные слои, функцию активации ReLU, регуляризацию L2 и слои Dropout.

```
model = Sequential()
model.add(Dense(64, input_dim=X_train.shape[1], activation='relu', kernel_regularizer=regularizers.l2(0.01))) # Input layer
model.add(Dropout(0.5)) # Dropout layer
model.add(Dense(32, activation='relu', kernel_regularizer=regularizers.l2(0.01))) # Hidden layer
model.add(Dropout(0.5)) # Dropout layer
model.add(Dense(1, activation='sigmoid')) # Output layer

# Компиляция модели
model.compile(loss='binary_crossentropy', optimizer='adam', metrics=['accuracy'])
```

Рис 5 – Код спроектированной нейронной сети для классификации

Первый слой модели — это полносвязный слой (Dense) с 64 нейронами, который использует функцию активации ReLU и применяет регуляризацию L2. ReLU — это функция активации, которая обеспечивает эффективное обучение глубоких нейронных сетей, обнуляя отрицательные входные значения и позволяя положительным значениям проходить без изменений. Регуляризация L2 борется с переобучением, добавляя штраф к весам с большим абсолютным значением, что в итоге уменьшает эти веса.

Следующим добавленным элементом в архитектуре является слой Dropout, который представляет собой метод регуляризации, основанный на случайном исключении определенного процента нейронов в процессе обучения. Такой подход способствует предотвращению переобучения, повышает устойчивость модели и снижает ее сложность.

Завершают модель еще один полносвязный слой с 32 нейронами, применяющий функцию активации ReLU и регуляризацию L2, а также выходной слой с одним нейроном, использующий функцию активации сигмоид. Последний слой модели, как правило, предсказывает вероятность принадлежности к положительному классу, что оказывается особенно полезным в задачах бинарной классификации.

Для обеспечения совместимости модели нейронной сети, созданной с использованием Keras, с функциями библиотеки eli5, в частности, с функцией Permutation Importance пришлось создать специальный класс Wrapper. Потому что библиотека eli5 предоставляет инструменты для анализа важности признаков в моделях машинного обучения. Однако, эти инструменты ожидают, что модель будет соответствовать определенному интерфейсу, который обычно используется в моделях из библиотеки scikit-learn. В частности, они ожидают, что модель будет иметь методы fit(), predict() и score().

Модели нейронной сети, созданные с использованием Keras, не следуют этому интерфейсу напрямую. Вместо этого они используют свой собственный набор методов и конвенций. Класс Wrapper служит промежуточным слоем,

который преобразует интерфейс модели Keras в интерфейс, совместимый с scikit-learn, позволяя таким образом использовать модель Keras с инструментами eli5.

```
class Wrapper:
    def __init__(self, model):
        self.model = model

    def predict(self, X):
        return self.model.predict(X) >= 0.5 # возвращает предсказанные метки класса, а не вероятности

    def fit(self, X, y):
        self.model.fit(X, y)

    def score(self, X, y):
        y_pred = self.predict(X)
        return accuracy_score(y, y_pred) # возвращает точность
```

Рис 6 – Код класса для работы с eli5

Применение Permutation Importance в сочетании с нейронной сетью в качестве классификатора представляет собой подход, который имеет ряд существенных преимуществ. Нейронные сети обладают возможностью моделировать сложные нелинейные зависимости, что может быть недоступно для более простых моделей, таких как логистическая регрессия или случайный лес. Перемешивание значений (Permutation Importance) дает возможность оценивать важность признаков, даже если они взаимодействуют друг с другом сложным и неочевидным образом.

Weight	Feature
0.0198 ± 0.0028	create-invoice
0.0126 ± 0.0020	click-btn-pay
0.0096 ± 0.0013	open-status-success
0.0019 ± 0.0006	open-status-error
0.0008 ± 0.0004	show-error-message
0.0007 ± 0.0002	scroll-ps-list
0.0007 ± 0.0004	choose-method-header
0.0007 ± 0.0004	open-payment-return
0.0006 ± 0.0005	click-show-more
0.0006 ± 0.0001	open-status-processing-error
0.0005 ± 0.0002	open-payment-payment-methods
0.0004 ± 0.0004	enter-email
0.0003 ± 0.0006	click-btn-return-url
0.0003 ± 0.0005	enter-card-number
0.0002 ± 0.0006	click-disallow-save-card
0.0002 ± 0.0003	enter-cvv
0.0002 ± 0.0001	click-cash-only
0.0001 ± 0.0002	change-status
0.0001 ± 0.0002	click-privacy_settings-save
0.0001 ± 0.0000	open-paystation
... 82 more ...	

Рис 7 – Вывод результата библиотекой Eli5 для спроектированной нейронной сети

В результате этот подход оказался наиболее эффективным, что, вероятно, связано с его способностью сочетать гибкость нейронной сети с надежной оценкой важности признаков, предоставляемой Permutation Importance. Способность моделировать сложные зависимости и учесть взаимосвязи признаков может быть ключевым фактором, определяющим успех этого подхода в данном контексте. В то время как выверенная и не перегруженная архитектура сети позволила достаточно быстро предсказывать результаты.

3.3.5. Ранговая система финального вывода

В контексте данного исследования была разработана совокупная система определения наиболее вероятных событий, основанная на концепции ранжирования признаков на основе их позиции в выходных данных различных методов анализа. Фундаментом этой системы служит принцип агрегации рангов, умноженных на коэффициенты точности соответствующих методов. Это позволяет придать больший вес более надежным и точным методам, обеспечивая при этом сбалансированный учет всех используемых подходов.

Name	Время выполнения	Оценка точности /10
Claster + Catboost	< 10 секунд	9
Eli + LogRegression	< 10 секунд	7
Eli + RendomForrest	< 10 секунд	7
Permutation Importance + logRegression	< 20 секунд	7
Permutation Importance + RendomForrest	< 30 секунд	8
NN + Eli	~ 120 секунд	10

Таблица 4 – Результаты работы подходов

Время выполнения – скорость выполнения в ячейке colab

Оценка точности – среди событий есть одно, которое есть только в успешных оплатах. Успешная модель должна была расположить его на первом месте, оценка отражает позицию этого события в топ 10, где первое место – 10 баллов

Специфика подобного подхода включает в себя расчет ранга каждого события в зависимости от его позиции в выходных данных каждого метода, умножение этого ранга на соответствующий коэффициент точности метода, который соответствует оценки точности, а затем суммирование полученных значений для каждого события. Финальное распределение признаков затем определяется на основе суммы рангов, деленных на общее количество использованных методов.

Такой подход к совокупному анализу данных представляет ряд существенных преимуществ. Во-первых, он позволяет учесть информацию,

полученную из различных источников или методов анализа, каждый из которых может выявить уникальные зависимости или структуры в данных. Во-вторых, использование коэффициентов точности позволяет придать больший вес более надежным и точным методам, повышая качество агрегированного анализа.

В контексте решаемой задачи, использование такой совокупной системы определения наиболее вероятных событий обеспечивает более глубокий и точный анализ данных. Это особенно важно при работе с данными веб-аналитики, где различные события могут иметь различный уровень важности для конечного результата. Таким образом, данный подход способствует более точному и обоснованному принятию решений на основе данных, внося значительный вклад в развитие и усовершенствование процессов аналитики и предсказания поведения пользователей.

3.4 Итоговая реализация

В конечном итоге был разработан автоматизированный скрипт, способный осуществлять ряд важных функций в рамках задачи анализа пользовательских данных. Главная цель этого скрипта – преобразование неструктурированных данных веб-аналитики в ценную информацию, способную помочь в определении наиболее важных событий пользователей для определенной искомой метрики.

Скрипт начинает свою работу с базового EDA включают чистку и масштабирование данных. После того, как все необходимые операции по обработке данных выполнены, скрипт приступает к определению наиболее важных событий пользователей. Здесь применяется совокупная система ранжирования событий, основанная на их важности для искомой метрики.

В результате работы скрипта формируется отчет, в котором указываются наиболее важные события пользователей для выбранной метрики. Это позволяет аналитикам данных использовать полученную информацию для оптимизации работы и сократить рутинные процессы.

Заключение

В ходе данной работы была выполнена задача разработки и реализации аналитического подхода к обработке и интерпретации пользовательских данных, полученных из внутренней системы веб-аналитики. Этот подход базировался на применении актуальных методик и алгоритмов машинного обучения и анализа данных.

Изначально было проведено подробное изучение исходных данных, их первичная обработка и подготовка для дальнейшего анализа. Основной исследовательской задачей было выявление внутренних зависимостей и структур в данных, что потребовало применения методов кластеризации и классификации.

Значимым моментом в работе стала определение значимости признаков с помощью метода Permutation Importance. Были использованы такие алгоритмы как логистическая регрессия, случайный лес, была применена нейронная сеть. Проведённый анализ показал, что нейронная сеть позволяет наиболее точно идентифицировать важные факторы, влияющие на пользовательские события и связанные с ними метрики.

Основной результат работы – разработанный скрипт, предназначенный для автоматической обработки и анализа данных. С его помощью можно автоматически выделять наиболее значимые для бизнес метрик пользовательские события, облегчая задачу аналитиков и улучшая стратегию взаимодействия с пользовательской аудиторией.

Полученный инструментарий важен не только для компании, где проводилось исследование, но и для широкого круга организаций, работающих в сфере цифровых технологий и веб-аналитики. Разработанный подход позволяет более эффективно исследовать поведение пользователей, применять полученные данные для улучшения продуктов и услуг.

С помощью функционала в период проведения работы была выявлена гипотеза, которая была передана команде разработки и была внедрена в продукт. На основании этого изменения был проведен АБ тест, который

показал статистически значимый прирост в конверсии от открытия продукта до оплаты пользователем (Lift + 10%). В результате был внедрен шаг с дополнительными методами оплаты на экран с ошибкой отсутствия средств в кошельке пользователя. Только на одной этой задаче было сэкономлено около 3 рабочих дней аналитика данных. Что в год может дать экономию около 20-25 рабочих дней. Прирост revenue в RU регионе составил 0.35%

В заключении хотелось бы отметить, что проведенное исследование является значимым вкладом в область аналитики пользовательских данных и может послужить основой для дальнейших исследований и разработок в этой сфере, имеет широкий потенциал для роста и развития и даже имеет возможность стать самостоятельным продуктом.

Библиографический список

1. Кто такие аналитики в IT и чем они занимаются [Электронный ресурс] // Хабр. – URL: <https://habr.com/ru/articles/657649/> (дата обращения: 27.04.2023)
2. Кошик А. Веб-аналитика 2.0 на практике. Тонкости и лучшие методики / А. Кошик. – Санкт-Петербург: Диалектика, 2019. – 528 с.
3. Яндекс. Метрика : офиц. сайт. – URL: <https://metrika.yandex.ru/> (дата обращения: 02.05.2023)
4. Google. Analytics : офиц. сайт. – URL: <https://analytics.google.com/> (дата обращения: 02.05.2023)
5. Adobe Analytics : офиц. сайт. – URL: <https://business.adobe.com/ru/products/analytics/adobe-analytics.html>
6. Amplitude : офиц. сайт. – URL: <https://amplitude.com/> (дата обращения: 03.05.2023)
7. Alhlou F., Asif S., Fettman E. Google Analytics Breakthrough: From Zero to Business Impact / Alhlou F., Asif S., Fettman E. – Wiley, 2016. - 624с
8. Microsoft Power Bi : офиц. сайт. – URL: <https://powerbi.microsoft.com/ru-ru/> (дата обращения: 02.06.2023)
9. Tableau : офиц. сайт. – URL: <https://www.tableau.com/> (дата обращения: 03.05.2023)
10. Обзор Google Data Studio [Электронный ресурс] // Школа веб-аналитики. – URL: <https://web-analytics.me/page497364> (дата обращения: 04.05.2023)
11. Qlick Sense : офиц. сайт. – URL: <https://www.qlik.com/us/products/qlik-sense> (дата обращения: 03.06.2023)
12. Yandex Cloud Datalens : офиц. сайт. – URL: <https://cloud.yandex.ru/services/datalens> (дата обращения: 03.05.2023)
13. Исследование рынка российских (и не только) BI-платформ [Электронный ресурс] // Хабр. – URL: <https://habr.com/ru/companies/axenix/articles/695960/> (дата обращения: 05.05.2023)

14. Pandas : офиц. сайт. – URL: <https://pandas.pydata.org/about/> (дата обращения: 07.05.2023)
15. Scikit-learn : офиц. сайт. – URL: <https://scikit-learn.org/stable/> (дата обращения: 07.05.2023)
16. Retentioneering : офиц. сайт. – URL: <https://retentioneering.com/> (дата обращения: 08.05.2023)
17. Prokhorenkova L. CatBoost: unbiased boosting with categorical features / Prokhorenkova L. Gusev G., Vorobev A., Dorogush V., Gulin A. [Электронный ресурс] // ArXiv. – URL: <https://arxiv.org/abs/1706.09516> (дата обращения: 20.04.2023)
18. Ribeiro M. Why Should I Trust You?: Explaining the Predictions of Any Classifier / Ribeiro M., Singh S., Guestrin C [Электронный ресурс] // ArXiv. – URL: <https://arxiv.org/abs/1602.04938> (дата обращения: 21.04.2023)
19. Fan. A. ELI5: Long Form Question Answering / Fan. A., Jernite Y., Perez E., Grangier D., Weston J., Auli M. [Электронный ресурс] // ArXiv. – URL: <https://arxiv.org/abs/1907.09190> (дата обращения: 23.04.2023)
20. Crawford, K. Big Data and Due Process: Toward a Framework to Redress Predictive Privacy Harms / Crawford, K., Schultz, J. // Boston College Law Review, Vol. 55, No. 93, 2014 – 37с – URL: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=2325784# (дата обращения: 23.04.2023)
21. Barocas, S. Big Data's Disparate Impact / Selbst, A. // 104 California Law Review 671, 2016 – 62с – URL: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=2477899# (дата обращения: 25.04.2023)
22. Zuboff, S. The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power. / Zuboff, S. – PublicAffairs, 2019 – 704с.
23. Pasin M. Generating large-scale network analyses of scientific landscapes in seconds using Dimensions on Google BigQuery / Pasin M., Abdill R.

[Электронный ресурс] // ArXiv. – URL: <https://arxiv.org/abs/2301.10736> (дата обращения: 15.05.2023)

24. Sculley D. Web Scale K–Means clustering / Sculley D – Proceedings of the 19th international conference on World wide web, Association for Computing Machinery, 2010 – 120с

25. Schubert E. DBSCAN revisited, revisited: why and how you should (still) use DBSCAN. / Schubert E., Sander J., Ester M., Kriegel H. P., Xu X. // ACM Transactions on Database Systems (TODS), 42(3), 19, 2017

26. Stella X. Yu Multiclass spectral clustering / Stella X. Yu, Jianbo Shi [Электронный ресурс] // Berkeley University Library. – URL: <https://people.eecs.berkeley.edu/~jordan/courses/281B-spring04/readings/yu-shi.pdf> (дата обращения: 01.05.2023)

27. Ankerst M. OPTICS: ordering points to identify the clustering structure / Ankerst M., Markus M., Kriegel H., Sander J. – ACM Sigmod Record, vol. 28, no. 2, pp. 49–60. ACM, 1999.

28. Arthur D. Proceedings of the twenty–second annual symposium on Computational geometry / Arthur D., Vassilvitskii S. – Association for Computing Machinery, 2006 – Pages 144–153.

29. Prokhorenkova L. CatBoost: unbiased boosting with categorical features / Prokhorenkova L. Gusev G., Vorobev A., Dorogush V., Gulin A. [Электронный ресурс] // ArXiv. – URL: <https://arxiv.org/abs/1706.09516> (дата обращения: 14.05.2023)

30. Fumagalli F. Incremental Permutation Feature Importance (iPFI): Towards Online Explanations on Data Streams / Muschalik M., Hüllermeier E., Hammer B. [Электронный ресурс] // ArXiv. – URL: <https://arxiv.org/abs/2209.01939> (дата обращения: 12.05.2023)